



Segmentation des clients Olist

PRÉSENTÉ PAR ANDRÉA NEBOT



Introduction

Olist est une entreprise brésilienne spécialisée dans les solutions de vente sur les marketplaces en ligne. Dans le cadre de ses opérations e-commerce, Olist cherche à améliorer ses campagnes de communication marketing en comprenant mieux le comportement de ses clients.

L'entreprise dispose d'une base de données anonymisée contenant des informations sur les commandes, les produits, les évaluations clients et la localisation, couvrant la période depuis janvier 2017. Elle sollicite une segmentation client actionnable, destinée à ses équipes marketing, à partir de méthodes non supervisées.



Attentes du client

- Fournir une segmentation de client exploitable
 - Différencier les "bons" des "mauvais clients"
 - Respecter la convention PEP8
 - La segmentation doit couvrir l'ensemble des clients
- recommandation sur la mise à jour du modèle pour planifier un contrat de maintenance

Point d'attention

- Peu de données disponibles (noms, prénoms, âges et sexe ne sont pas intégrés)
- Données hétérogènes et bruitées
 - Stabilité dans le temps

Problématique

Comment segmenter efficacement l'ensemble des clients d'Olist, à partir de données comportementales limitées, afin d'aider l'équipe marketing à cibler ses actions, tout en garantissant la pertinence et la stabilité de cette segmentation dans le temps ?



1. Exploration et nettoyage



2. Création des features et
essais



3. Modèle final



4. Simulation et Contrat de
maintenance



1.Exploration et nettoyage



9

Datasets

111705

Lignes

97916

ID clients




29

Variables

20


Catégories de
produits




0	identifiant_client	111705	non-null	object
1	identifiant_unique_client	111705	non-null	object
2	code_postal_client	111705	non-null	object
3	ville_client	111705	non-null	object
4	état_client	111705	non-null	object
5	identifiant_commande	111705	non-null	object
6	statut_commande	111705	non-null	object
7	horodatage_achat_commande	111705	non-null	object
8	date_commande	111705	non-null	object
9	heure_commande	111705	non-null	object
10	année	111705	non-null	int32
11	mois	111705	non-null	int32
12	mois_année	111705	non-null	object
13	jour	111705	non-null	int32
14	paiement_séquentiel	111705	non-null	float64
15	type_paiement	111705	non-null	object
16	nombre_paiements	111705	non-null	float64
17	montant_paiement	111705	non-null	float64
18	identifiant_avis	111705	non-null	object
19	note_avis	111705	non-null	float64
20	identifiant_article_commande	111705	non-null	float64
21	identifiant_produit	111705	non-null	object
22	identifiant_vendeur	111705	non-null	object
23	prix	111705	non-null	float64
24	frais_livraison	111705	non-null	float64
25	code_postal_vendeur	111705	non-null	object
26	ville_vendeur	111705	non-null	object
27	état_vendeur	111705	non-null	object
28	categorie_produit	111705	non-null	object


dtypes: float64(7), int32(3), object(19)

Matrice de corrélations






Ventes par Etats




Ventes par Etats


Categorie Produit







2. Création des features et essais






Méthode de Regroupement des Clients

Nous avons mis en œuvre une méthode de clustering non supervisée afin de regrouper les clients d'Olist selon des critères objectifs: fréquence d'achat, diversité des produits commandés, régularité des achats, localisation et niveau de satisfaction. L'analyse des comportements d'achat depuis 2017 permet ainsi d'identifier des patrons d'usage, révélant plusieurs groupes types au sein de la clientèle.


Chaque segment est donc le fruit d'une similarité observée dans ces comportements mesurés, garantissant une grande pertinence opérationnelle pour les prochaines campagnes marketing ciblées. Cette approche facilite un ciblage spécifique, adapté à la diversité du portefeuille client d'Olist.

Liste des variables créés



Test avec K-means

Clusters - t-SNE



Cluster 0

Les clients
très récents et
peu engagés

Cluster 1

Les clients
récents à
potentiel
moyen

Cluster 2

Clients
récents, panier
élevé, note
faible

Cluster 3

Les clients
très
dépensiers et
fidèles



Cluster 4

Clients
ponctuels,
récents et
satisfaits

Cluster 5

Clients récents,
satisfait et
solvables


Test avec HDBSCAN



Le meilleur parametrage est donc celui-ci :

min_cluster_size:300 min_samples:70 eps:0.8 n_clusters:5

Tests et résultats HDBSCAN



Cluster
-1

Client
Premium /
Fidélisé

Cluster 0

Petit panier,
forte
fréquence

Cluster 1

Peu engagé

Cluster 2

Explorateur
potentiel

Cluster 3

Engagement
moyen

Cluster 4

Dormant /
Faible activité

Comparaisons

K-means

Nécessite de fixer k , sensible aux outliers, forme sphérique attendue.

DBSCAN/HDBSCAN

DBSCAN : détecte les formes variées, robuste aux outliers (label -1), mais nécessite de régler ϵ et min_samples , plante quand il y a trop de données, nous avons donc du utiliser HDBSCAN plus performant, qui peut mieux identifier des clients marginaux ou des comportements atypiques dans une stratégie de fidélisation ou de gestion du risque.

Clients Premium / Dépensiers

	KMeans - Cluster 3	HDBSCAN - Cluster -1
Montant total	2279€	2758€
Panier moyen	1276€	703€
Paiements	6.72	4.28
Fréquence	~1 / mois	36 / mois (à vérifier)
Note moyenne	3.86	3.90
Interprétation	Gros acheteurs réguliers	Ultra premium, probablement pros
Reco marketing	Programme VIP, early access	Account manager, offres exclusives

Ces deux clusters identifient bien une population à haute valeur. HDBSCAN permet d'isoler plus naturellement ces profils sans bruit.

Clients dormants ou peu engagés

	KMeans - Cluster 0	HDBSCAN - Cluster 4
Recence	403 jours	244 jours
Commandes	1.02	1.0
Montant total	125€	188€
Note moyenne	4.53	4.11
Taille	~équilibrée	91 000+ clients (!)
Interprétation	Acheteurs inactifs	Acheteurs uniques / dormants
Reco marketing	Campagnes de retour, retargeting	Réactivation massive, nurturing

HDBSCAN identifie un cluster de dormants beaucoup plus massif, ce qui reflète peut-être mieux la réalité commerciale. KMeans dilue ces profils dans des groupes artificiellement équilibrés.

Clients récents, curieux / explorateurs

	KMeans - Cluster 1 ou 5 ?	HDBSCAN - Cluster 2
Var. catégories	1.75 ou 1.01	2.0
Note moyenne	4.24 / 4.56	4.26
Commandes	2.18 / 1.02	2.07
Recence	~180 jours / 246 jours	181 jours
Interprétation	Clients à potentiel / récents	Explorateurs, satisfaits
Reco marketing	Cross-selling, découverte	Bundles, produits variés

KMeans semble segmenter davantage selon montant ou récence, alors que HDBSCAN regroupe les curieux et satisfaits avec des comportements similaires de variété.

Clients insatisfaits à fort potentiel

	KMeans - Cluster 2	HDBSCAN - Cluster 1
Panier moyen	152€	224€
Note moyenne	1.21	2.97
Paiement fractionné	54%	3.9 paiements moyens
Recence	243 jours	213 jours
Interprétation	Gros paniers mais très insatisfaits	Similaire mais moins extrême
Reco marketing	Analyse SAV, compensation	Sondage, reconquête

KMeans permet ici d'isoler un cluster très insatisfait avec de gros paniers. HDBSCAN regroupe ce profil dans un cluster plus hétérogène. KMeans est plus précis ici.

Recommandation finale

HDBSCAN est plus pertinent pour identifier les profils extrêmes (VIP, dormants, explorateurs), mais nécessite une validation métier.

KMeans est plus facile à interpréter et mieux adapté pour des campagnes marketing structurées, surtout si on veut des groupes d'action marketing équilibrés.


Stratégie idéale : Utiliser KMeans pour l'activation marketing (fidélisation, segmentation CRM) et HDBSCAN pour la détection de profils spécifiques (VIP, outliers).



3. Simulation et Contrat de maintenance



Simulation mensuelle




ARI KMeans très variable, allant de négatif à 0.5+, fluctue beaucoup.

ARI HDBSCAN aussi très variable, souvent négatif ou proche de 0.

NMI HDBSCAN beaucoup plus stable et élevée (~0.6-0.8), mieux que KMeans qui est très volatile.

Simulation trimestrielle




AARI KMeans autour de 0.05 - 0.23 (similaire semestrielle, plus de points).

ARI HDBSCAN un peu meilleur que semestrielle parfois (par ex 0.11), mais toujours faible ou négatif.

NMI HDBSCAN reste nettement supérieur à KMeans (0.68 vs 0.12), ce qui montre une meilleure cohérence d'information pour HDBSCAN.

Simulation semestrielle



ARI KMeans : de 1 à 0.05, globalement assez stable, tend vers 0.2 sur la période.

ARI HDBSCAN : globalement plus bas, parfois négatif, autour de 0.05 en moyenne.

NMI HDBSCAN est plus élevé que KMeans (~0.7 vs 0.12), ce qui signifie que la structure d'information est mieux capturée par HDBSCAN en terme d'information mutuelle.

Recommandations : Mise à jour trimestrielle



Après analyse des résultats, la mise à jour **mensuelle** présente une variabilité trop importante, avec des indices ARI faibles ou négatifs et un faible nombre de clients communs, limitant la fiabilité et la cohérence des segments.

À l'inverse, la segmentation **trimestrielle** présente un compromis optimal : elle offre une meilleure stabilité des clusters, des mesures de similarité (ARI, NMI) plus favorables, et un nombre de clients communs suffisant pour garantir une segmentation cohérente et exploitable.

De plus, la fréquence trimestrielle optimise les ressources de calcul et s'intègre mieux aux cycles marketing, évitant les changements trop fréquents qui pourraient nuire à la lisibilité et à l'efficacité des campagnes.



Merci

